RAG-LEIS · FASE 2 · CONJUNTO OURO

Validar o gabarito do dev

Passo a passo para conferir, à mão, as 39 perguntas de desenvolvimento em `results/validacao_gold.md`

39
perguntas marcadas com **(dev)**.
As 36 do *test* ficam para depois.

4
checagens por pergunta.
As mesmas, sempre na mesma ordem.

~1h30
em 3 blocos de cerca de 30 min.
É uma estimativa: 2 min por pergunta.

POR QUE ISTO VEM ANTES DE TUDO

Gabarito validado
você confere pergunta, artigo e resposta esperada

›

Rotular 30 respostas
a coluna *correta* compara com a resposta esperada

›

Concordância ≥ 80%
juiz `gemma3:12b` contra os seus rótulos

›

Fase 4 fechada
experimentos da fase 5 liberados

Se a resposta esperada estiver errada, o rótulo **correta** sai errado, a concordância com o juiz sai errada e todo número da fase 5 herda o erro. Hoje o gabarito foi redigido e revisado pelo mesmo LLM: **0 de 75** perguntas foram lidas por uma pessoa.

O CAMINHO EM 5 ETAPAS

1. **Preparar** — terminal, atalho `ver` e o arquivo aberto
2. **Entender a ficha** — o que cada linha da pergunta significa
3. **Conferir** — 4 checagens contra o texto do artigo
4. **Decidir** — marcar `[x]` ou corrigir o gabarito
5. **Fechar** — contar, testar e fazer o commit

ONDE VOCÊ MARCA
`results/validacao_gold.md`
uma caixa por pergunta

ONDE VOCÊ LÊ A LEI
`data/processed/corpus.jsonl`
406 artigos, pelo atalho `ver`

ONDE VOCÊ CORRIGE
`data/gold/gold.jsonl`
só se achar defeito

ETAPA 1

1 Preparar a mesa de trabalho

≈ 2 min · uma vez por sessão

terminal · cole o bloco inteiro

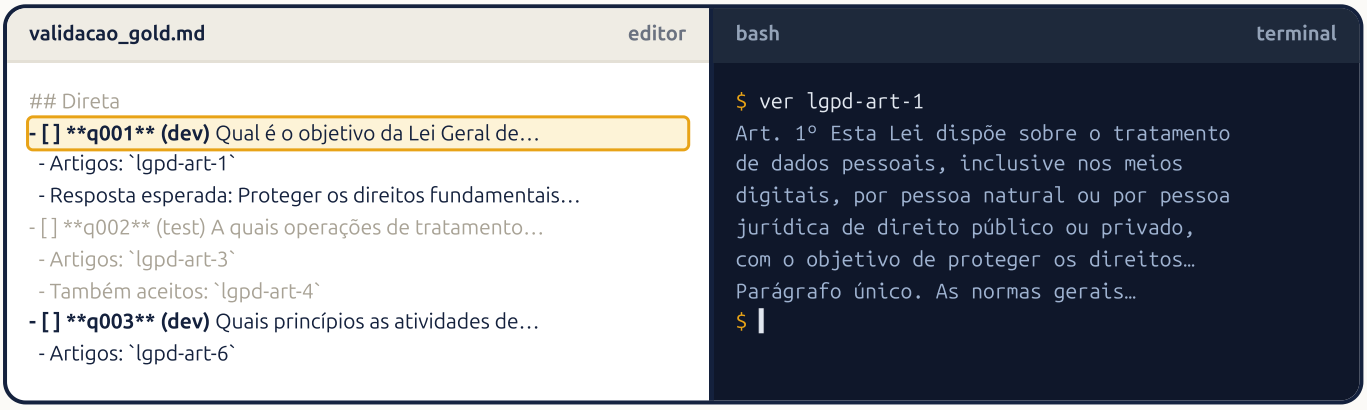
```
$ cd ~/rag-leis && source .venv/bin/activate

# atalho: mostra o texto de um artigo pelo id
$ ver() { grep "\"$1\"" data/processed/corpus.jsonl |
    python -c "import json; print(json.loads(input())['texto'])"; }

# abre a lista de perguntas no VS Code
$ code results/validacao_gold.md
```

O atalho `ver` vale só para o terminal em que foi colado. Abriu outro terminal, cole de novo. O Ollama **não** precisa estar ligado para validar.

Como a tela deve ficar



à esquerda: a ficha da pergunta

à direita: o artigo que ela aponta

Pular de uma pergunta do dev para a próxima

No VS Code, `Ctrl+F` e busque `(dev)`. `Enter` salta para a seguinte e pula as de *test*. As seções começam nas linhas 39 (Direta), 126 (Leiga), 193 (Vários artigos), 227 (Termo exato) e 261 (Fora do escopo): `Ctrl+G` leva direto.

Regras para o gabarito continuar valendo

Não abra as respostas do sistema
`results/baseline/saidas.jsonl` e `rotular.md` ficam fechados. Quem vê o que o sistema respondeu tende a ajustar o gabarito a ele.

Não peça a um LLM para validar
Essa revisão já foi feita e está registrada no topo do arquivo. Ela não conta: o que falta é a leitura de uma pessoa.

Não mexa nas linhas (test)
Elas serão validadas antes da medição final. Agora, só as 39 marcadas com `(dev)`.

Leia o artigo inteiro
Caput, parágrafos e incisos. Prazos e exceções costumam estar nos parágrafos, não na primeira frase.

ETAPA 2

2 Entender a ficha de uma pergunta

A ☐ **q007** dev

B Quem responde pelos danos causados pelo tratamento de dados pessoais em violação à lei?

C Artigos: `lgpd-art-42`

D Também aceitos: `lgpd-art-43` `lgpd-art-44`

E Resposta esperada: O controlador ou o operador que causar dano patrimonial, moral, individual ou coletivo é obrigado a repará-lo. O operador responde solidariamente quando descumpre a legislação…

A — Caixa, id e split
A caixa é o que você marca. Só trabalhe nas de `(dev)`.

B — Pergunta
O que o usuário digitaria.

C — Artigos esperados
Precisam ser recuperados. O recall é calculado sobre eles.

D — Também aceitos
Ajudam a responder, mas não substituem o esperado. Só 7 perguntas do dev têm.

E — Resposta esperada
O gabarito. O juiz e você vão comparar a resposta do sistema com este texto.

ETAPA 3

3 As 4 checagens

≈ 2 min por pergunta

Rode `ver <id>` para cada artigo da ficha (esperados **e** aceitos) e responda às quatro perguntas abaixo, nesta ordem. Um único "não" já manda a pergunta para correção.

1 O artigo é o certo?

O artigo esperado contém a resposta, e é o lugar mais direto da lei para ela.

Reprova se: a resposta está em outro artigo, ou precisa de um segundo artigo que não está listado.

2 A resposta está no texto?

Cada afirmação da resposta esperada aparece no artigo. Confira número por número: prazos, valores, percentuais.

Reprova se: há um dado que o artigo não traz, ou falta o ponto principal.

3 A pergunta é clara?

Uma pessoa entenderia sem ver o artigo, e só existe uma resposta razoável.

Reprova se: é ambígua, ou cabe uma resposta diferente apoiada em outro artigo.

4 O tipo confere?

A pergunta testa o que a seção diz que testa. Os critérios de cada tipo estão na página 5.

Reprova se: uma "leiga" usa as palavras da lei, ou uma "fora do escopo" tem resposta no corpus.

O que NÃO é defeito

Resposta esperada com palavras diferentes das da lei, mas o mesmo conteúdo. Resposta que resume uma lista longa com "entre outros", desde que o essencial esteja lá. Anotações como "(Incluído pela Lei nº…)" dentro do artigo: fazem parte do corpus de propósito.

O corpus é a régua, não a sua memória da lei

O gabarito tem de bater com o texto que está em `corpus.jsonl`, baixado do Planalto em 9/10/2026. Exemplo: a **q057** usa R$ 100.000,00 e R$ 50.000,00 para dispensa, que são os valores do art. 75. A atualização por decreto não está no corpus, então a resposta esperada está certa para este projeto.

EXEMPLO RESOLVIDO

A q001, do começo ao fim

A FICHA · VALIDACAO_GOLD.MD

Pergunta. Qual é o objetivo da Lei Geral de Proteção de Dados Pessoais?

Artigos. `lgpd-art-1`

Resposta esperada. Proteger os direitos fundamentais de liberdade e de privacidade e o livre desenvolvimento da personalidade da pessoa natural, disciplinando o tratamento de dados pessoais, inclusive nos meios digitais.

O ARTIGO · ver lgpd-art-1

Art. 1º Esta Lei dispõe sobre o tratamento de dados pessoais, inclusive nos meios digitais, por pessoa natural ou por pessoa jurídica de direito público ou privado, com o objetivo de proteger os direitos fundamentais de liberdade e de privacidade e o livre desenvolvimento da personalidade da pessoa natural.

Parágrafo único. As normas gerais contidas nesta Lei são de interesse nacional e devem ser observadas pela União, Estados, Distrito Federal e Municípios.

1 · Artigo ✓
O art. 1º declara o objetivo. Nenhum outro é mais direto.

2 · Resposta ✓
Os dois trechos marcados aparecem no artigo. "Disciplinando" no lugar de "dispõe sobre": mesmas ideias.

3 · Clareza ✓
Só há um "objetivo da lei". Sem ambiguidade.

4 · Tipo ✓
Seção Direta: pergunta formal, um artigo. Confere.

Aprovada
- [x] **q001**

ETAPA 4

4 Decidir e registrar

Ler a ficha
pergunta, artigos, resposta

›

ver <id>
ler cada artigo até o fim

›

4 checagens
todas passaram?

›

Sim: aprovar
troque [ ] por [x] e siga

Não: corrigir, depois marcar
edite `gold.jsonl` (página 6)

Como fica no arquivo

aprovada sem mudança

```
- [x] **q001** (dev) Qual é o objetivo da…
  - Artigos: `lgpd-art-1`
  - Resposta esperada: Proteger os…
```

aprovada depois de corrigida

```
- [x] **q013** (dev) Qual é o prazo de…
  - Artigos: `cdc-art-27`
  - Resposta esperada: (texto novo)
  - Corrigido: prazo estava incompleto.
```

O segundo quadro é só ilustração do formato; a q013 não tem defeito conhecido. A linha `Corrigido:` é o registro do que você mudou e por quê.

A caixa marcada significa uma coisa só

"Uma pessoa leu o artigo e a ficha está certa do jeito que está agora." Por isso a pergunta corrigida também termina com [x]. Em dúvida que não consegue resolver, deixe [ ], escreva - `Dúvida:` … embaixo e continue. Salve com `Ctrl+S` a cada punhado de perguntas: as caixas marcadas mostram onde retomar.

3+

CHECAGEM 4 EM DETALHE

O que olhar em cada tipo

14 + 10 + 5 + 5 + 5 = 39

14 Direta

linha 39 do arquivo

O caso básico: pergunta formal, um artigo.

O trabalho aqui é quase todo a checagem 2. Listas longas (princípios, sanções, critérios) precisam ser conferidas item por item contra os incisos.

q009 · Quais sanções administrativas podem ser aplicadas a quem descumpre a LGPD?

ATENÇÃO

Números. Na q009, confira "2% do faturamento", "R$ 50 milhões" e "6 meses" no art. 52. No CDC os prazos vêm por extenso ("trinta dias").

10 Linguagem leiga

linha 126 do arquivo

Testa a busca por significado.

A pergunta tem de soar como alguém sem formação jurídica e **não** pode repetir os termos do artigo. Compare o vocabulário da pergunta com o do artigo.

q036 · Chegou na minha casa um produto que eu nunca pedi. Sou obrigado a pagar?

ATENÇÃO

Se a pergunta copia palavras raras da lei ("titular", "controlador", "inexigibilidade"), ela vira direta disfarçada e a busca fica fácil demais. Reescreva.

5 Vários artigos

linha 193 do arquivo

Dois artigos esperados, os dois necessários.

Rode `ver` nos dois. Tape um com a mão: a resposta esperada ainda fica completa só com o outro? Se sim, o segundo não é necessário.

q049 · Quem é o encarregado pelo tratamento de dados e quais são as suas atividades?

ATENÇÃO

Cada artigo tem de sustentar uma parte diferente da resposta. Na q049: o art. 5º define o encarregado, o art. 41 lista as atividades.

5 Termo exato

linha 227 do arquivo

Testa a busca por palavra-chave.

A pergunta cita o número do artigo ou um termo técnico. Confira se o número citado bate com o id esperado e se a resposta resume o artigo sem inventar.

q059 · O que dispõe o art. 193 da Lei 14.133?

ATENÇÃO

Número certo, lei certa. "Art. 37 da Lei 13.709/2018" tem de apontar para `lgpd-art-37`, não para o art. 37 do CDC.

5 Fora do escopo

linha 261 do arquivo

Sem artigo: o acerto é o sistema dizer que não sabe.

Aqui a checagem é invertida. Você procura o tema no corpus e confirma que **nenhum** artigo responde. Não há `ver` a rodar; use a busca abaixo.

q067 · Qual o prazo para entrar com ação trabalhista?

ATENÇÃO

A palavra aparecer não quer dizer que o corpus responde. Leia o contexto de cada ocorrência antes de decidir.

procurar um tema no corpus

```
# em quantos artigos aparece (0 = tema ausente)
$ grep -ic "furto" data/processed/corpus.jsonl
0
$ grep -ic "trabalhista" data/processed/corpus.jsonl
13

# apareceu? veja o contexto de cada ocorrência
$ grep -io ".\{50\}trabalhista.\{50\}" \
    data/processed/corpus.jsonl
```

0 não basta, 13 não reprova

Com 0, tente um sinônimo antes de aprovar. "Trabalhista" aparece em 13 artigos: leia os contextos e confirme que nenhum fala em *prazo para entrar com ação*.

q075 é a mais delicada

O art. 60 da LGPD cita o Marco Civil. Rode `ver lgpd-art-60` e confirme que ele não traz o prazo de guarda de registros.

ETAPA 4, RAMO DO "NÃO"

Achou um defeito. E agora?

sem defeito? pule para a etapa 5

A correção é sempre em `data/gold/gold.jsonl`, que é a fonte da verdade: uma linha por pergunta. Ache a linha pelo id (`Ctrl+F` → `"q013"`), edite só o campo com defeito e repita o texto novo na ficha de `validacao_gold.md`.

O QUE VOCÊ ENCONTROU	CAMPO A EDITAR	O QUE FICA DESATUALIZADO
Outro artigo responde melhor que o esperado	`artigos_esperados` troque o id	A Métricas de busca
Outro artigo também ajuda a responder	`artigos_aceitos` acrescente o id	A Métricas de busca
A resposta esperada traz dado que o artigo não tem, ou omite o ponto principal	`resposta_esperada` reescreva a partir do artigo	B Veredito do juiz para esse id
Pergunta ambígua, ou leiga com palavras da lei	`pergunta` reescreva	C Resposta do sistema e veredito do juiz
Fora do escopo que tem resposta no corpus	`pergunta` troque por outro tema ausente	C Resposta do sistema e veredito do juiz

Cuidados ao editar o JSON

Cada pergunta é uma linha só: não quebre a linha. Mantenha as aspas duplas e as vírgulas. Não apague perguntas (os testes exigem dev e test equilibrados por tipo): prefira corrigir. Rode `pytest tests/test_gold.py` depois de cada edição; ele acusa JSON quebrado e id de artigo que não existe.

Refazer o que ficou desatualizado

Anote os ids corrigidos e faça isto **uma vez, no fim**, não a cada pergunta. Troque q013 pelo id corrigido. B e C precisam do Ollama ligado (`ollama serve` em outro terminal).

A Busca

Código puro, sem LLM. Recalcula recall e MRR do dev em segundos.

```
python -m rag_leis.evaluate
```

B Juiz

Apaga o veredito antigo e julga só o que falta. Cerca de 1 a 2 min por pergunta.

```
sed -i '/"id": "q013"/d' results/baseline/julgamentos_gemma3-12b.jsonl
export RAG_LEIS_JUIZ=gemma3:12b
python -m rag_leis.evaluate --juiz
```

C Resposta + juiz

Apaga a saída antiga e gera a nova (cerca de 1 min por pergunta). Depois faça o **B**.

```
sed -i '/"id": "q013"/d' results/baseline/saidas.jsonl
python -m rag_leis.baseline
```

Se qualquer coisa do dev mudou, regenere a amostra de rotulagem

`python -m rag_leis.evaluate --rotular` reescreve `rotular.md` com o gabarito corrigido. Ele também zera `rotulos.csv`: hoje o arquivo está vazio, então não se perde nada, mas faça isso **antes** de começar a rotular, nunca depois.

PLANO DE TRABALHO

Três blocos de meia hora

tempos estimados

Bloco A ≈ 30 min
14 diretas

Bloco B ≈ 25 min
10 leigas

Bloco C ≈ 35 min
15 vários · termo · fora

Mapa das 39 perguntas · imprima e risque, ou acompanhe pelas caixas do arquivo

Direta 14 · bloco A	☐ q001	☐ q003	☐ q005	☐ q007	☐ q009	☐ q011	☐ q013	☐ q015
	☐ q017	☐ q019	☐ q021	☐ q023	☐ q025	☐ q027		
Leiga 10 · bloco B	☐ q028	☐ q030	☐ q032	☐ q034	☐ q036	☐ q038	☐ q040	☐ q042
	☐ q044	☐ q046						
Vários artigos 5 · bloco C	☐ q047	☐ q049	☐ q051	☐ q053	☐ q055			
Termo exato 5 · bloco C	☐ q057	☐ q059	☐ q061	☐ q063	☐ q065			
Fora do escopo 5 · bloco C	☐ q067	☐ q069	☐ q071	☐ q073	☐ q075			

☐ q000 tem artigos em "Também aceitos": rode `ver` neles também (7 perguntas).

5

ETAPA 5

Fechar

≈ 5 min

terminal · conferir e registrar

```
# 1. quantas do dev estão marcadas? tem de dar 39
$ grep -c '\[x\] \*\*q[0-9]*\*\* (dev)' results/validacao_gold.md
39
# 2. o gabarito continua íntegro?
$ pytest tests/test_gold.py
# 3. só se corrigiu alguma pergunta: refazer A, B ou C da página 6 e depois
$ python -m rag_leis.evaluate --rotular
# 4. registrar
$ git add results/validacao_gold.md data/gold/gold.jsonl results/baseline
$ git commit -m "Registra a validação humana das perguntas do dev"
```

Atualize a documentação
No `README.md` e no `DIARIO.md`: fase 2 com dev validado, falta o test. Anote quais perguntas foram corrigidas.

E as 36 do test?
Mesmo método, linhas (`test`). Prazo: antes da única medição no test, no fim da fase 5.

Pronto quando: 39 caixas do dev marcadas e `pytest` verde.
Próximo passo do projeto: rotular as 30 respostas em `results/baseline/rotular.md` e rodar `python -m rag_leis.evaluate --concordancia`.